



西南财经大学
SOUTHWESTERN UNIVERSITY OF FINANCE AND ECONOMICS

2026 年 《博弈论》课程报告

汇报题目： 非合作博弈视角下的信任机制研究—以《弥留之国的爱丽丝红心游戏为例》

所在学院： 计算机与人工智能学院

专 业： 计算机科学与技术

学 号： 42311180

学生姓名： 刘俊宏

成 绩：

2026 年 6 月

非合作博弈视角下的信任机制研究——以《弥留之国的爱丽丝》红心游戏为例

摘要

影视文本因具有情境具体、冲突集中和人物行为可观察等特点，逐渐成为博弈论教学与社会科学分析中的重要案例来源。本文以《弥留之国的爱丽丝》中的红心 7“躲猫猫”和红心 J“单人牢房”为研究对象，尝试从博弈论视角分析死亡游戏中的信任机制、非合作行为与策略选择。文章借鉴影视博弈分析中的场景化处理方法，将剧情冲突转化为玩家、策略、收益结构、信息结构和可能均衡，并结合关键决策节点、得益矩阵与反事实路径，解释人物在合作、背叛、牺牲和验证之间作出选择的原因。红心 7“躲猫猫”中，游戏规则规定最终只有“狼”能够存活，其他“羊”则面临死亡，由此形成高度零和的生存竞争结构。本文将其视为熟人关系嵌入零和规则后的非合作博弈，重点分析友情承诺为何难以稳定、口头让渡为何缺乏执行力，以及牺牲行为如何体现收益函数的变化。红心 J“单人牢房”中，玩家无法观察自身花色，只能依赖他人提供信息，而隐藏身份的红心 J 具有操控信息和破坏信任的动机。本文将其视为信息不对称条件下的动态信任博弈，重点讨论信号传递、重复互动、联盟形成和有限信任在玩家决策中的作用。研究认为，红心 7 与红心 J 并非简单并列，而是在信任问题上形成了由收益结构到信息结构的分析推进：前者呈现规则明确但收益高度零和时，熟人之间的承诺为何难以稳定；后者呈现信息高度不对称、身份隐藏且互动重复时，陌生人之间的信任如何被建立、利用与破坏。二者共同说明，红心游戏的残酷性并不只来自死亡惩罚，而在于规则设计改变了玩家的收益关系和信息条件，使许多看似可行的合作路径难以形成稳定结果。本文由此指出，人物选择并非单纯由情绪或性格决定，而是在规则、信息、收益和偏离动机共同作用下形成的策略结果。

关键词：《弥留之国的爱丽丝》；非合作博弈；零和博弈；信息不对称；信任机制；纳什均衡

1 引言

博弈论关注多个决策主体在相互影响条件下如何选择。与孤立决策不同，博弈结果不仅取决于个体自身行动，也取决于其他参与者的策略、信息与预期。因此，玩家、策略、收益、信息结构与均衡构成了分析战略互动的基本要素。无论是市场竞争、政治谈判、组织协作，还是日常生活中的信任、承诺与背叛，只要一名行动者的收益受到他人选择影响，该情境就可以被纳入博弈论的分析框架。尤其是在资源有限、结果排他、信息不完全或缺乏外部强制契约的场景中，个体行为往往不能被简单理解为道德选择，而需要被解释为行动者在规则、收益、风险与他人预期共同约束下形成的策略回应。

影视文本为理解这类战略互动提供了较有价值的案例入口。相较于纯粹公式化模型，影视作品通常具有明确场景、可观察行为和高度集中的冲突结构，能够把抽象的博弈关系转化为具象叙事。已有研究表明，影视场景可以用于辅助理解博弈论中的策略互动、均衡和激励问题^[1]。但如果只把影视作品作为概念举例，分析容易停留在“剧情对应理论”的层面；更有解释力的做法，是从规则出发识别玩家之间的收益关系、信息条件和偏离动机，再讨论人物选择为何在特定结构下出现。本文正是在这一意义上使用《弥留之国的爱丽丝》：它不是被当作简单故事素材，而是被视为一组被叙事化呈现的战略互动实验。

《弥留之国的爱丽丝》中的游戏按照扑克牌花色区分类型。黑桃游戏偏向体力竞争，方块游戏偏向智力推理，梅花游戏偏向团队协作，而红心游戏则更集中地考验心理压力、人际信任与背叛风险。红心游戏的特殊性在于，它并不只是用死亡惩罚提高情节紧张度，而是通过规则重新组织

玩家之间的关系：原本的朋友可能因为唯一生存名额而成为竞争者，陌生人也可能因为信息依赖而被迫合作。换言之，红心游戏真正残酷之处并不只在于失败会导致死亡，而在于游戏规则会改变玩家的收益函数和信息环境，使“相信谁”“是否合作”“能否承诺”“如何验证”等问题变成直接影响生死的战略问题。

本文选择红心 7“躲猫猫”和红心 J“单人牢房”作为研究案例，是因为二者同属红心游戏，却分别呈现两类不同的信任困境。红心 7 中，游戏规则相对清晰：最终只有处于“狼”身份的玩家能够存活，其余“羊”身份玩家死亡。此时，问题并不主要来自信息缺失，而来自唯一生存名额制造的收益排他性。即使有栖良平、苅部大吉和势川张太之间原本存在友情，规则仍会持续削弱口头承诺的可信性。红心 J 中，玩家无法看到自己的花色，只能依赖他人告知；同时，隐藏身份的红心 J 有动机操控信息、制造误判并破坏信任。此时，合作并非没有必要，恰恰相反，玩家必须合作才能获得自身花色信息，但这种合作又始终受到虚假信号和身份隐藏的威胁。

因此，红心 7 与红心 J 并不是两个可以简单并列的剧情片段，而是构成了一个从收益冲突到信息冲突的分析序列。红心 7 展示的是规则明确但收益高度零和时，熟人关系为何难以保证合作承诺；红心 J 展示的是收益并非完全排他但信息高度不对称时，陌生人之间的信任如何被建立、利用和破坏。前者关注“承诺为什么不可信”，后者关注“信号为什么不可靠”。这种差异使二者适合被放入同一研究框架中比较：它们都讨论信任，却分别揭示信任失效的不同机制。

基于上述观察，本文的核心问题可以概括为三个方面。第一，在死亡惩罚和强规则约束下，红心游戏中的合作为何难以稳定。第二，红心 7 和红心 J 分别通过何种收益结构或信息结构改变玩家之间的信任关系。第三，若人物选择不同路径，例如提前约定牺牲顺序、共同寻找规则漏洞、公开互报花色或固定搭档，这些替代策略是否具备稳定性。第三个问题尤其重要，因为它能够避免论文停留在事后解释层面。一个替代方案看起来更善良、更聪明或更公平，并不意味着它能在原规则下维持；关键在于该方案是否存在偏离动机、偏离是否可被阻止、信息是否足够、验证成本是否可承受。

为回答这些问题，本文采用“规则识别—决策节点拆解—模型转化—均衡解释—反事实检验”的分析路径。首先，本文从游戏规则出发，提取玩家、策略、收益与信息条件。其次，本文将剧情压缩为若干关键决策节点，避免按照剧情顺序做线性复述。再次，本文通过简化得益矩阵和信任策略比较，说明人物选择背后的结构性约束。最后，本文引入反事实路径讨论，用以检验替代方案的稳定性。需要说明的是，本文并不试图证明影视剧情完全符合标准博弈模型，也不把人物简化为完全自利的理性人；相反，本文关注的是在特定规则下，不同偏好、情感和信息如何进入收益排序，并影响最终策略结果。

本文的可能贡献主要体现在三个方面。第一，在研究对象上，本文将《弥留之国的爱丽丝》中的红心游戏作为博弈论分析案例，补充既有研究中偏重人物成长、媒介改编和游戏化学习的讨论。第二，在分析框架上，本文区分收益结构与信息结构两个层面：红心 7 用于解释零和规则如何削弱承诺可信性，红心 J 用于解释信息不对称如何塑造有限信任。第三，在论证方式上，本文不仅分析原剧情中的人物选择，还通过反事实路径讨论替代方案的稳定性，从而说明人物行为并非单纯由情绪或性格决定，而是在规则、信息、收益和偏离动机共同作用下形成的策略结果。由此，本文希望说明红心游戏的残酷性不仅来自死亡惩罚，更来自规则与信息对玩家关系的重新组织。

2 相关工作

本文主要借鉴三类研究：博弈论及其影视化教学研究、《弥留之国的爱丽丝》相关文本研究，以及非合作博弈、信息不对称与信号传递等理论研究。它们为本文提供了方法基础，但对红心游戏中规则如何改变信任关系的讨论仍有展开空间。

博弈论研究为本文提供了基本分析语言。Osborne 和 Rubinstein^[2] 强调，互动决策中个体收益不仅取决于自身行动，也取决于其他玩家的行动。Gibbons^[3] 则说明，应将现实互动转化为玩家、策略和收益函数。本文据此把红心游戏中的人物理解为在规则约束下作出策略选择的玩家。

影视文本的博弈论教学研究则提供了场景化处理方法。Dixit^[4] 指出，现实感和趣味性较强的材料有助于降低博弈论理解门槛；Geerling 等^[1] 对《鱿鱼游戏》的分析也表明，影视作品中的规则、冲突和选择可以被拆解为可讨论的博弈场景。本文借鉴这一做法，但重点不在剧情复述，而在识别规则背后的收益结构、信息条件和均衡压力。

关于《弥留之国的爱丽丝》的既有研究也说明该作品具有分析价值。Anggrela 等^[5] 关注有栖良平在死亡游戏中的人格发展，Khan 和 Pembecioğlu^[6] 则从游戏化学习、协作生活和问题解决能力等角度理解该剧。不过，相关研究更多讨论人物成长或媒介意义，对具体规则如何塑造收益结构、信息限制和信任机制的分析仍相对有限。

在理论层面，非合作博弈有助于解释红心 7 中的承诺失效。红心 7 规定最终只有“狼”能够存活，使玩家之间形成接近零和的收益结构；在缺乏外部强制契约时，口头承诺难以约束失败者重新争夺狼身份。纳什均衡的思想也能说明：若某一策略组合下仍存在单方面改善自身结果的可能，合作便难以稳定。

信息不对称和信号传递理论则有助于解释红心 J。Akerlof^[7] 指出，信息差异会深刻影响互动结果；Harsanyi^[8] 说明，不完全信息博弈中的玩家只能基于有限信息判断他人类型；Spence^[9] 关于信号传递的讨论，则可用于理解红心 J 中“告知花色”的行为。由于真实信号可以帮助他人生存，虚假信号可能导致他人死亡，信任必须在重复互动、声誉积累和交叉验证中被不断检验。

综上，现有研究为本文提供了博弈论框架、影视案例化方法和文本研究基础。本文的切入点是进一步比较红心 7 与红心 J：前者强调收益排他性与承诺可信性，后者强调信息不对称与信号验证，并通过反事实路径检验替代策略的稳定性。

3 红心 7 的非合作博弈分析

红心 7“躲猫猫”发生在植物园式场地内，主要参与者为有栖良平、苣部大吉、势川张太和紫吹小织。游戏规则可以概括为：初始状态下有一名玩家为“狼”，其余玩家为“羊”；当狼与羊发生对视后，狼的身份会转移给被对视的羊；倒计时结束时，只有最终处于狼身份的玩家能够存活。该规则直接把玩家关系转化为围绕唯一生存名额展开的竞争关系。

因此，红心 7 的分析重点不是复述朋友如何从合作走向冲突，而是解释熟人关系为何难以抵消零和规则带来的偏离动机。若某一玩家最终成为狼，该玩家获得生存收益，其他玩家则承担死亡损失。友情仍然存在，但它被嵌入了“一人生存意味着他人死亡”的收益结构之中。

从博弈要素看，有栖、苣部、张太、紫吹等人均可视为玩家；可选策略包括争夺狼身份、逃避对视、隐藏自身、作出口头承诺或主动牺牲。玩家知道基本规则，也知道狼身份可以通过对视转移，因此信息条件并不复杂；真正困难的是，规则本身削弱了承诺的稳定性，使红心 7 更接近零和博弈的非合作生存博弈。

这种规则结构具有明显的非合作特征。玩家可以交流，也可以尝试建立承诺，但游戏没有提供外部执行机制。尤其在倒计时后期，任何仍处于羊身份的玩家都面临死亡压力，其偏离承诺并重新争夺狼身份的动机会显著增强。合作并非完全不可能，但很难稳定。

从决策过程看，玩家并不是抽象地面对“生存还是死亡”，而是在规则公布、身份转移、口头承诺、倒计时后期和结局前选择等节点上不断重新判断。前期玩家可能仍保留合作幻想，但随着倒计时推进，零和特征不断强化，个体生存收益被放大，合作关系也更容易被重新解释为策略风险。

为了进一步说明红心 7 中的非合作压力，可以将其简化为两名玩家之间的策略互动。这里以有栖良平和苧部大吉为例进行模型化处理。需要强调的是，得益矩阵中的数值不是对人物心理收益的实证测量，而是参照影视博弈案例教学中常见的做法^[1]，根据剧情规则对相对收益进行顺序化编码。矩阵只要求表达不同结果之间的大小关系，而不要求数值具有精确计量意义。

该矩阵的赋值依据如下。第一，最终成为狼并存活是规则给出的最高收益，因此记为 10。第二，作为羊死亡是游戏中的最低结果，因此记为 -10。第三，双方都争夺狼身份时，二人都付出关系破裂、搏斗和心理崩溃的代价，但至少仍保留改变身份的机会，因此用 -5 表示一种高冲突、低稳定但并非立即接受死亡的状态。第四，双方都放弃争夺时，友情和道德意义得到保留，但无人能够稳定取得生存资格，结局仍趋向共同死亡，因此记为 -8。这一排序体现的是“生存收益最高、死亡损失最低、冲突状态优于直接放弃但伴随重大关系成本”的剧情判断。

表 1: 红心 7 中有栖良平与苧部大吉的简化得益矩阵

	苧部争夺狼身份	苧部放弃争夺
有栖争夺狼身份	$(-5, -5)$	$(10, -10)$
有栖放弃争夺	$(-10, 10)$	$(-8, -8)$

从表 1 可以看出，如果玩家只以个体生存作为最高收益，那么争夺狼身份具有较强的策略吸引力。当对方放弃争夺时，自己争夺可以获得最高收益。当对方争夺时，自己若放弃则几乎确定死亡，若争夺至少仍有改变结果的可能。因此，在纯粹生存理性下，玩家很难稳定地选择放弃争夺。剧情中朋友从搏斗转向躲藏和牺牲，恰恰说明他们最后并非沿着狭义生存收益最大化行动，而是让友情、愧疚和继承意志进入收益函数。

这也解释了为什么口头承诺面临可信性问题。某一玩家可以承诺自己不会争夺狼身份，也可以承诺让他人活下去，但其他玩家无法确认该承诺在最后时刻仍会被遵守。从纳什均衡视角看，只要单方面争夺狼身份能够改善自身结果，原有合作就难以稳定。因此，在以生存为最高收益的基础模型中，非合作策略具有很强吸引力。

红心 7 的特殊之处在于，剧情并没有停留在纯粹的生存竞争。随着游戏推进，人物之间的情感关系、愧疚感和自我认同开始改变个体对收益的理解。对于标准博弈模型而言，生存通常被设定为最高收益，死亡则是最低收益。然而，红心 7 中的牺牲行为表明，人物的收益函数可能并不只包含生理生存，还可能包含朋友能否存活、自身是否背叛友情、是否保留道德意义等因素。

因此，红心 7 的结局不能简单解释为非理性行为。若玩家将“让朋友活下去”视为一种高于自身生存的价值，那么主动牺牲就不再是收益最小化，而是偏好结构改变后的策略选择。这种选择不符合狭义的自利理性，却可以在扩展收益函数中获得解释。换言之，人物并不是不知道争夺狼身份可以提高生存概率，而是在最后阶段重新定义了什么才是对自己而言更重要的结果。

已有角色研究也能从叙事层面支撑这一点。Anggrela 等^[5]认为，朋友的死亡与牺牲构成有栖

人格变化的重要节点。本文进一步指出，当朋友存活、道德责任和继承意志被纳入个体收益函数时，牺牲或接受牺牲就不再只是单纯的非理性行为，而是收益排序变化后的策略结果。

由此可见，红心 7 呈现出的不是单一人物的性格悲剧，而是零和规则、时间压力和承诺不可信共同作用下的结构性困境。剧情结尾的躲藏与牺牲并非简单否定博弈理性，而是说明人物在规则压力下重新调整了收益排序。

4 红心 J 的信息信任博弈分析

如果说红心 7 的核心问题是收益排他性，那么红心 J“单人牢房”的核心问题则是信息不对称。该游戏发生在监狱场景中，参与者包括苕屋骏太郎、盘田素那斗、松下苑治、矢场旺希、琴子及其他玩家。所有玩家佩戴颈环，后颈处显示扑克牌花色；玩家无法看到自己的花色，只能依靠他人告知。每过一小时，玩家必须回到单人牢房回答花色，答错者死亡，答对者进入下一回合。游戏没有总时限，通关条件是使混入玩家中的红心 J 答错花色并死亡。

因此，红心 J 并非单纯的猜测游戏，而是围绕信息真实性展开的动态信任博弈。玩家必须依赖他人获取生存信息，却无法确认信息是否真实；红心 J 同样需要他人信息维持生存，却又有动机误导普通玩家、破坏信任并隐藏身份。由此，信息成为决定生死的核心资源。

从博弈要素看，苕屋、盘田、松下、矢场、琴子及其他参与者均是玩家，其中松下是隐藏身份的红心 J。普通玩家的策略包括如实告知、寻求他人告知、固定结盟、交叉验证、怀疑与排除；红心 J 的策略则包括隐藏身份、选择性提供真实信息、制造误导、破坏联盟和诱导错误回答。由此，红心 J 可以被理解为不完全信息博弈、信号传递博弈和重复博弈的结合，其主要矛盾是信任建立与信息操控之间的冲突。

红心 J 的复杂性来自双重信息不对称。其一，玩家掌握他人花色信息，却无法直接观察自身花色，因而必须依赖他人告知；其二，普通玩家不知道谁是红心 J，也无法判断他人提供信息时究竟出于合作、试探还是误导。红心 J 同样不知道自己的花色，却可以利用他人对信息的依赖制造不确定性。正是这两重不确定性，使红心 J 中的信任关系高度不稳定。

在这种规则结构下，理性策略既不是简单相信所有人，也不是完全拒绝他人信息。完全信任容易被虚假信号操控，完全不信任又会切断必要信息。因此，红心 J 的核心问题不是“信任或不信任”的二分，而是在不完全信息环境中如何建立有限信任、进行交叉验证，并持续更新判断。

红心 J 的决策节点主要围绕信息可信度展开。玩家需要判断向谁询问花色，是否相信对方提供的信息，是否与某人固定结盟，是否公开共享信息，以及是否怀疑某人具有红心 J 身份。随着游戏推进，玩家会根据历史准确率、他人评价和交叉验证更新判断；一旦出现可疑信息，又必须在继续信任、降低信任、主动试探和公开质疑之间选择。

这说明，红心 J 的博弈过程具有明显的动态性。玩家并不是在某一时刻一次性决定是否信任他人，而是在多轮互动中不断修正判断。某个玩家在前几轮提供正确信息，并不意味着其在后续回合一定继续可信。相反，隐藏身份的红心 J 可能通过前期合作建立声誉，再在关键节点释放错误信息，从而实现更有效的误导。由此可见，红心 J 中的信任并不是静态状态，而是一种不断被生产、检验和重估的策略资源。

红心 J 中的“报花色”行为可以被视为一种典型的信号传递。观察到他人花色的玩家拥有信息优势，无法观察自身花色的玩家则处于信息劣势。前者通过语言告知后者花色：若信号真实，接收者可以存活；若信号虚假，接收者可能死亡。

然而，信号能否被相信，并不只取决于信号内容本身，还取决于信号发送者的身份、动机和

历史行为。普通玩家提供真实花色，可能是为了互相合作并延长生存时间。红心 J 提供真实花色，则可能是为了隐藏自己并积累可信声誉。红心 J 提供虚假花色，则可能是为了淘汰其他玩家并制造群体恐慌。因此，相同的“告知花色”行为，在不同玩家类型下具有不同含义。

红心 J 中的信息流并不是单向透明的，而是由观察、告知、验证和怀疑共同构成。信任的建立通常依赖重复互动：若某一玩家连续多轮提供正确信息，其可信度会上升，其他玩家也更愿意与其结盟。但隐藏敌人同样可以利用真实信号伪装成合作者，借局部合作换取长期信任。因此，声誉能够降低不确定性，却不能消除背叛风险。

在红心 J 中，玩家面临三种基本信任策略。完全信任的沟通成本最低，但一旦对象是红心 J 或关键时刻背叛，风险极高。完全不信任看似能避免欺骗，却会切断获取自身花色所必需的信息来源。相较而言，有限信任与交叉验证更符合规则环境：玩家可以暂时相信某一信息源，但通过询问多人、比较信息一致性和观察历史行为降低被单一虚假信号误导的概率。该策略并不能彻底消除风险，却能在信息依赖和背叛防范之间取得相对平衡。

由此可见，红心 J 的理性策略并不是绝对合作，也不是绝对孤立，而是在有限信任基础上的动态验证。这与红心 7 形成鲜明对比。红心 7 中，合作承诺之所以困难，是因为唯一生存名额使玩家之间的收益高度冲突。红心 J 中，合作之所以困难，则是因为信息真实性无法被立即确认。前者的问题是收益结构接近零和，后者的问题是信息结构高度不对称。

为了进一步说明红心 J 中的信任困境，可以将其简化为信息接收者与信息发送者之间的互动。这里的玩家 A 代表需要获知自身花色的信息接收者，玩家 B 代表掌握 A 花色信息的发送者；B 既可能是普通玩家，也可能是隐藏红心 J 或其暗中同盟。因此，矩阵并不假定所有普通玩家都有说谎收益，而是刻画“信息发送者具有欺骗动机”时，接收者如何在直接信任与交叉验证之间选择。若 A 直接信任且 B 说真话，双方都能以较低成本通过本回合。若 A 直接信任而 B 说假话，A 可能因答错花色死亡，B 则可能获得淘汰对手、制造混乱或保护隐藏身份的收益。若 A 交叉验证，则会付出沟通和时间成本，但能够降低被单一虚假信号杀死的风险。

表 2: 红心 J 中信息告知与信任选择的简化得益矩阵

	信息发送者 B 说真话	信息发送者 B 说假话
玩家 A 直接信任	(5, 5)	(-10, 8)
玩家 A 交叉验证	(3, 4)	(2, -3)

表 2 中的数值同样是相对收益，其依据来自剧情中“如实告知—顺利过关”“虚假告知—答错死亡”“交叉询问—降低风险但增加成本”的规则关系。(5, 5) 表示前期玩家如实互报花色时的高效率合作：A 获得正确信息，B 也积累合作声誉。(-10, 8) 表示 A 直接相信谎言后的死亡损失，以及 B 在欺骗成功时获得的淘汰竞争者或扰乱信任网络收益；该收益低于红心 7 中的生存最高值，是因为说谎会留下声誉风险和身份暴露风险。(3, 4) 表示 A 进行交叉验证且 B 说真话时，双方仍可生存，但验证成本和被怀疑的成本使收益低于无成本信任。(2, -3) 表示 A 通过验证识别或抵消谎言后避免死亡，B 则因说谎暴露而承担声誉下降、联盟破裂或身份被锁定的损失。琴子向矢场提供错误花色、苺屋通过询问和观察其他四人的反应判断花色，并最终推断松下身份的情节，正对应这一验证机制的作用。

从均衡角度看，红心 J 难以形成“所有人完全信任”的稳定状态。只要群体中存在隐藏的红心 J，虚假信号就始终具有策略价值；但所有人完全不信任也无法稳定，因为玩家无法独立观察自己

的花色。更可能出现的是一种“有限信任均衡”：玩家需要交换信息，同时保留验证机制和怀疑空间，并根据历史行为、他人反馈和信息一致性调整可信度。

通过上述分析可以看出，红心 J 中不存在绝对安全的策略。玩家必须依赖他人信息才能生存，却不能把生死完全交给单一信号。因此，红心 J 并不是简单说明“相信别人会死”或“不相信别人才可能活”，而是呈现了信息依赖、验证成本与背叛风险之间的持续权衡。

5 两种红心游戏的比较

通过前文分析可以看出，红心 7 与红心 J 虽然都属于红心类游戏，但二者的博弈结构并不相同。红心 7 的核心资源是唯一生存名额，玩家的主要目标是争夺最终的狼身份；红心 J 的核心资源则是真实信息，玩家的主要目标是获得关于自身花色的可靠判断，并识别隐藏在群体中的红心 J。前者的冲突来自规则直接制造的生存排他性，后者的冲突来自信息不对称造成的信任不确定性。

本文所说的“分析推进”并不是指二者之间存在直接剧情因果关系，而是指它们在信任机制问题上呈现出由基础困境到复杂困境的展开。红心 7 展示规则明确条件下的收益冲突：玩家知道最终只有一人能够存活，因此信任失效主要源于唯一生存名额造成的零和收益结构。红心 J 则进一步加入信息不对称、身份隐藏和重复互动，玩家不仅要考虑他人是否有背叛动机，还要判断他人提供的信息是否真实。二者共同说明，红心游戏的残酷性不只来自死亡惩罚，更来自规则与信息对玩家关系的重构。

具体而言，红心 7 发生在熟人关系中，友情和情感纽带原本存在，但“最终只有狼能存活”的规则使生存竞争压倒口头承诺；红心 J 发生在陌生人关系中，玩家必须依靠临时联盟获得花色信息，却无法确认信息发送者的身份与意图。前者的信息结构相对明确，问题集中在收益冲突和承诺不可信；后者的信息结构高度不对称，问题集中在信号真实性和验证成本。

因此，两个游戏虽然都围绕信任展开，但信任失效的机制不同。红心 7 中，只要最终只能有一人存活，合作承诺就会受到死亡风险的持续冲击，失败者也始终存在偏离动机；红心 J 中，即使玩家具有合作意愿，也无法确认他人是否真实、稳定、无害地提供信息。概括地说，红心 7 中的困境更接近“利益冲突下的承诺不可信”，红心 J 中的困境更接近“信息不对称下的信号不可信”。

博弈论分析强调，玩家行动不能脱离规则与收益结构来理解。将这一思路应用到红心游戏中可以发现，人物行为并非单纯由性格决定，而是在特定规则下被重新塑造的。红心 7 中，规则将生存收益与他人死亡结果绑定，使口头约定缺少执行基础；红心 J 中，规则让每名玩家都必须依赖他人信息，使信息发送者获得策略优势。由此，规则不是背景，而是决定玩家关系的核心机制。

这两种机制也对应两种有限合作逻辑。红心 7 中的合作只有在玩家收益函数发生变化时才可能稳定，例如牺牲者将朋友生存视为高于自身生存的价值；红心 J 中的合作只有在验证机制存在时才更可靠，例如玩家通过多人交叉确认和多轮观察降低虚假信号风险。前者说明合作需要偏好基础，后者说明合作需要信息基础。

这一点可以回应本文开头提出的问题。关键人物为什么没有选择其他路径，并不是因为他们完全没有选择，而是因为多数路径缺乏稳定条件。角色看似可以选择合作、隐瞒、背叛或牺牲，但这些选择能否成为稳定结果，取决于收益结构是否支持，信息条件是否允许，偏离行为是否能够被约束。

综合前文，红心 7 与红心 J 之间的分析推进可以概括为三层：玩家关系从熟人扩展到陌生人，核心资源从生存名额转换为可靠信息，理论问题从承诺不可信推进到信号不可信。本文并不简单

评价人物是否善良、背叛或牺牲，而是分析这些选择在何种规则下成为合理策略，又在何种信息条件下失去稳定性。

6 反事实路径与策略稳定性

这里的反事实推演并不是为了改写剧情，而是回答：如果角色换一种做法，结果是否会更好？从博弈论角度看，关键并不在于某条路径看起来是否更善良、更聪明或更公平，而在于它能否在原有规则下保持稳定。if 分析检验的是替代方案能否同时处理生存压力、信息限制和偏离动机。

红心 7 最容易引发的疑问是：既然有栖良平、苺部大吉和势川张太是好友，他们是否可以一开始就商量出一个更和平的办法？第一种可能是由四人提前约定让某一个人活下去。这种做法在情感上比相互搏斗更可接受，但它的问题在于缺少执行机制。只要倒计时没有结束，狼的身份仍然可以通过对视转移，任何处于羊身份的人都会在死亡压力下重新面对“是否偏离约定”的诱惑。因此，这一路径的脆弱之处不是人物不够真诚，而是承诺本身无法被规则锁定。

第二种可能是四人始终聚在一起，尝试寻找规则漏洞或共同通关方式。这个路径更符合观众对“朋友应该一起想办法”的期待，也最接近集体理性。但红心 7 的规则明确把最终生存条件绑定在狼身份上，剧情中也没有提供足够清晰的共同通关线索。在时间持续减少的情况下，寻找漏洞会变成一种高风险搜索：如果找不到漏洞，玩家最终仍要回到唯一生存名额的竞争中。也就是说，这一方案不是完全不合理，而是缺少足够信息支撑，难以成为稳定策略。

第三种可能最接近实际剧情，即有人放弃争夺，让有栖活下去。它能够形成明确结果，却不是一般意义上的理性均衡。苺部、势川张太和紫吹小织最后躲藏起来，并不是因为他们找到了可普遍复制的最优策略，而是因为友情、愧疚、责任和“让有栖继续活下去”的意义改变了他们的收益排序。若换成没有深厚情感关系的玩家，这一路径很难自动出现。因此，红心 7 的 if 线真正说明的是，合作或牺牲并非没有可能，但它们要么缺少执行机制，要么缺少信息基础，要么依赖特殊情感偏好。

红心 J 的反事实问题则不同。观众更容易追问：既然大家只要互相说真话就能活下去，为什么不能一直公开互报花色？这一设想在游戏前期确实有效，因为当所有玩家都如实交换信息时，回答花色几乎没有难度。但红心 J 混在玩家之中，且胜利条件要求红心 J 死亡。只要红心 J 有动机隐藏身份并制造错误信息，全员公开就不是一个可以长期依赖的制度。它的最大弱点在于过分依赖“所有人都诚实”这一前提，而游戏正是通过隐藏敌人破坏这个前提。

另一种自然设想是稳定搭档。剧情中苺屋曾依靠忠厚良善的搭档顺利通过多轮，矢场与琴子、盘田与松下也都形成过搭档关系。搭档策略的好处是成本低、沟通快、责任明确，也更容易通过重复互动建立信任。但它的风险同样明显：一旦搭档本身不可信，玩家就会把生死过度集中在一个信息源上。矢场与琴子的关系正说明，稳定关系未必等于真实信息；松下与盘田的搭档关系也说明，弱者姿态本身可能成为伪装。

更稳健的路径是有限信任与多方验证。苺屋在最后阶段没有固定搭档，却通过询问、观察和分析剩余玩家反应判断自己的花色，并进一步锁定松下身份。这一路径并不追求最高效率，而是优先降低单一信息源带来的致命风险。它的代价是沟通成本更高，也需要玩家具备较强观察能力；但在隐藏敌人已经准备发动攻势的后期，它比单纯相信某个搭档更能抵抗欺骗。因此，红心 J 的 if 线并不是要证明“越怀疑越好”，而是说明信任必须配合验证，才能从情感关系转化为可持续的策略机制。

综合来看，两个游戏的反事实路径都指向同一个问题：替代方案不能只看表面是否更好，还

要看它是否能承受规则压力。红心 7 中的和平约定会被唯一生存名额和身份可转移规则削弱，红心 J 中的公开合作会被隐藏身份和虚假信号破坏。真正有解释力的 if 分析，不是简单说“他们本来可以这样做”，而是进一步追问：这样做之后，谁有动机偏离？偏离能否被阻止？信息是否足够？代价是否可承受？正是在这些问题上，红心 7 与红心 J 显示出博弈论分析的意义。

7 结论

本文围绕《弥留之国的爱丽丝》中的红心 7“躲猫猫”和红心 J“单人牢房”，提出一个基于博弈论的解释框架：红心游戏的关键不只是死亡惩罚，而是规则如何通过收益结构与信息结构重组玩家之间的信任关系。本文将角色行动转化为玩家策略，将剧情冲突转化为收益、信息、承诺与偏离动机之间的互动关系。

本文的第一个发现是，红心 7 中的信任困境主要来自收益结构。唯一生存名额把熟人关系嵌入接近零和的竞争环境，使口头承诺缺乏稳定执行基础。即使玩家之间存在友情，只要狼身份仍可在最后阶段转移，处于死亡风险中的玩家就始终存在偏离承诺的动机。

第二个发现是，红心 J 中的信任困境主要来自信息结构。玩家无法观察自身花色，只能依赖他人告知；隐藏身份的红心 J 又可以通过真假混合的信号操控判断。由此，信任不再是稳定的道德关系，而成为需要通过重复互动、声誉积累和交叉验证不断检验的策略资源。完全信任容易被利用，完全不信任又会切断必要信息，相对稳健的策略是有限信任与动态验证。

第三个发现是，红心 7 与红心 J 构成了从“收益冲突”到“信息冲突”的分析推进。前者说明，当规则直接制造生存排他性时，合作承诺会因偏离动机而失稳；后者说明，当规则制造信息不对称和身份隐藏时，合作关系会因信号不可信而失稳。二者共同揭示了红心游戏的制度性压力：规则不仅决定玩家能否活下去，也决定信任能否成为稳定策略。

本文的理论贡献在于，将影视文本中的红心游戏处理为可比较的博弈结构，而不是单一剧情案例。通过区分收益结构与信息结构，本文说明信任失败至少存在两种机制：零和收益压迫下的承诺失效，以及不完全信息环境中的信号失真。反事实路径的讨论也进一步检验了替代策略是否存在偏离动机、信息缺口和验证成本。

本文也存在局限。影视文本包含情感表达、人物成长和戏剧化安排，不能被完全还原为标准博弈模型；文中的得益矩阵只表达相对收益排序，并不构成对角色心理收益的精确测量；本文也仅选取两个红心游戏作为案例，尚未覆盖其他花色游戏。未来研究可以进一步比较不同花色游戏的策略结构，或引入演化博弈、机制设计和实验博弈方法，检验不同规则如何改变合作、欺骗与信任的边界。

总体而言，红心 7 和红心 J 以叙事方式呈现了理性选择中的两个核心问题：当生存收益彼此冲突时，承诺如何失效；当信息无法直接验证时，信任如何被建立、利用和破坏。正是在这一意义上，《弥留之国的爱丽丝》中的红心游戏不仅是死亡游戏叙事，也可以被视为理解非合作博弈、有限信任和均衡条件的案例模型。

参考文献

- [1] GEERLING W, NAGY K, RHEE E, et al. Using squid game to teach game theory[J]. Journal of Economics Teaching, 2023, 8(1): 47-63.

- [2] OSBORNE M J, RUBINSTEIN A. A course in game theory[M]. Cambridge, MA: MIT Press, 1994.
- [3] GIBBONS R. A primer in game theory[M]. Hemel Hempstead: Harvester Wheatsheaf, 1992.
- [4] DIXIT A. Restoring fun to game theory[J/OL]. The Journal of Economic Education, 2005, 36(3): 205-219. DOI: 10.3200/JECE.36.3.205-219.
- [5] ANGGRELA R F, BUDIMAN F F J, FEBRIYANTI S D. Arisu's personality development across the death games in alice in borderland[J]. Mahakarya: Jurnal Mahasiswa Ilmu Budaya, 2021, 2(2): 63-69.
- [6] KHAN M, PEMBECIOĞLU N. Generation Z-game based analytical thinking and problem-solving skills in digital world vs. collaborative life: "Alice in borderland" analysis[Z]. 2023.
- [7] AKERLOF G A. The market for lemons: quality uncertainty and the market mechanism [J/OL]. The Quarterly Journal of Economics, 1970, 84(3): 488-500. DOI: 10.2307/1879431.
- [8] HARSANYI J C. Games with incomplete information played by bayesian players, I–III[J/OL]. Management Science, 1967, 14(3): 159-182. DOI: 10.1287/mnsc.14.3.159.
- [9] SPENCE M. Job market signaling[J/OL]. The Quarterly Journal of Economics, 1973, 87(3): 355-374. DOI: 10.2307/1882010.