

红心游戏中的信任博弈——以《弥留之国的爱丽丝》为例

摘要

近年来，影视文本逐渐成为博弈论教学与社会科学分析中的重要案例来源。与传统数字化模型相比，影视叙事能够通过具体人物、极端情境与可观察行为呈现战略互动的过程，使“玩家”“策略”“收益”“信息”与“均衡”等概念具有更直观的解释空间。极端情境并不意味着分析对象脱离现实意义，反而能够将日常互动中相对隐蔽的理性计算、求生本能与信任冲突集中放大，使博弈关系以更纯粹的形式显现。本文以《弥留之国的爱丽丝》中的红心 7“躲猫猫”与红心 J“单人牢房”为研究对象，尝试将死亡游戏中的剧情冲突转化为博弈论模型，分析在高压生存情境中个体理性与本能反应被充分激发后，信任机制、非合作行为与策略选择之间的关系。

本文借鉴影视博弈分析中的场景化处理方法，将剧情拆解为若干关键决策节点，并依次识别其中的玩家、可选策略、收益结构与可能均衡。红心 7 中，游戏规则规定最终只有“狼”能够存活，其他“羊”则面临死亡，由此形成高度零和的生存竞争结构。本文将其视为一个由熟人关系嵌入零和规则后的非合作博弈，重点讨论友情承诺为何难以稳定、个体理性为何会压倒集体最优，以及牺牲行为如何体现收益函数的变化。红心 J 中，玩家无法观察自身花色，只能依赖他人提供信息，同时隐藏身份的红心 J 具有操控信息与破坏信任的动机。本文将其视为信息不对称条件下的动态信任博弈，重点分析信号传递、重复互动、联盟形成与贝叶斯信念更新在玩家选择中的作用。

研究认为，红心 7 与红心 J 之间存在明显的理论递进关系：前者呈现的是零和生存规则对熟人信任的瓦解，后者则进一步展示信息不对称环境中陌生人信任机制的生成、利用与崩塌。二者共同说明，《弥留之国的爱丽丝》中的红心游戏并非单纯依靠残酷剧情制造冲突，而是通过规则设计改变玩家的收益结构，使合作、背叛、牺牲与验证均成为特定制度环境下的理性选择。本文旨在说明人物并非没有行动选项，而是在既定规则、信息限制与收益压力下，难以找到同时满足生存、合作与稳定的最优路径。

关键词：《弥留之国的爱丽丝》；非合作博弈；零和博弈；信息不对称；信任机制；纳什均衡

1 引言

博弈论关注的是多个决策主体在相互影响条件下如何作出选择的问题。与单个个体的孤立决策不同，博弈论强调个体行为的结果不仅取决于自身策略，也取决于其他参与者的策略选择。因此，在博弈论分析中，“玩家”“策略”“收益”“信息结构”与“均衡”构成了理解战略互动的基本要素。无论是市场竞争、政治谈判、社会合作，还是日常生活中的信任与背叛，只要一个人的选择会受到他人选择的影响，就可以被纳入博弈论的分析框架之中。

近年来，流行影视作品也被用于解释经济学和博弈论概念。相较于抽象公式和纯理论模型，影视文本具有情境具体、冲突集中、人物行为可观察等特点，能够将复杂的战略互动转化为更直观的案例。已有研究表明，以影视场景辅助博弈论教学，有助于学习者从具体情境中理解玩家、策略、收益和均衡等核心概念^[1]。《弥留之国的爱丽丝》本身也已经进入学术分析视野，相关研究分别从有栖良平的人格发展^[2]，以及游戏化思维、协作学习和决策能力^[3]等角度讨论该作品。这说明该剧并不只是娱乐文本，也可以作为分析人物选择、规则压力和决策能力的研究对象。本文在此基础上进一步关注影视剧情的模型化分析，即如何将死亡游戏中的规则、人物和行为转化为可讨论的博弈结构。




图 1：红心 7 与红心 J 的规则结构及博弈特征比较

基于这一方法，本文选择《弥留之国的爱丽丝》中的红心 7“躲猫猫”和红心 J“单人牢房”作为研究案例。之所以选择这两个游戏，是因为它们同属于红心类型，均以心理压力、信任关系和背叛风险为核心，但二者的博弈结构又具有明显差异。红心 7 发生在较小规模的熟人群体之中，主要矛盾是唯一生存名额与既有情感关系之间的冲突；红心 J 则发生在较大规模的陌生人群体之中，核心矛盾是信息不对称条件下真实信息的获取、验证与操控。前者更适合用于分析零和博弈、不可信承诺和个体理性与集体理性的冲突，后者则更适合用于分析信号传递、重复博弈、联盟形成和信念更新。二者结合，能够形成从“生存名额竞争”到“信息信任竞争”的理论递进。如图 1 所示中解释了两种游戏的具体规则以及博弈结构的比较。

在红心 7 中，玩家被分为“狼”与“羊”。游戏结束时，只有狼能够存活，羊则会死亡。这一规则使得玩家之间的关系被直接改造为零和关系，即一名玩家的生存往往意味着其他玩家的死亡。在这种结构下，即便玩家之间原本存在友情、信任或道德承诺，这些关系也会受到生存收益的强烈冲击。本文关注的问题并不是简单判断人物是否自私或是否善良，而是分析在规则规定“只能有一人存活”的前提下，为什么合作承诺难以稳定，以及为什么最后的牺牲行为需要通过收益函数变化而非普通理性选择来解释。

与红心 7 相比，红心 J 的复杂性主要来自信息结构。玩家无法看到自己项圈后的花色，只能依靠他人告知。与此同时，隐藏在玩家中的红心 J 具有误导他人、制造不信任并延长自身生存的动机。因此，红心 J 并不是简单的猜测游戏，而是一个围绕信息真实性展开的动态博弈。玩家必须不断判断他人提供的信息是否可信，也必须通过结盟、观察、交叉验证和试探来降低被欺骗的风险。在这一过程中，完全信任会使玩家容易被操控，完全不信任又会导致信息断裂和生存风险上升。因此，红心 J 为分析“有限信任”“声誉机制”和“贝叶斯式信念更新”提供了较为典型的叙事场

景。

本文的研究目标并不是证明影视作品完全符合标准博弈论模型。相反，影视作品作为叙事文本，往往包含情感、偶然性、人物成长和戏剧化处理，其复杂程度不可能被单一模型完全覆盖。因此，本文采用的是一种“模型化解释”而非“完全形式化证明”的路径，并借鉴 Geerling 等^[1] 在影视案例教学中“先交代剧情与规则，再转化为玩家、策略、收益和均衡问题”的组织方式。本文首先提取游戏规则中与战略互动有关的部分，其次识别关键决策节点，再将人物转换为玩家，将行为转换为策略，将剧情结果转换为收益结构，最后结合得益矩阵和均衡分析解释人物选择的合理性与局限性。换言之，本文关注的是，在给定规则和信息条件下，人物为什么会作出某种选择，以及这些选择是否能够构成稳定均衡。

围绕上述问题，本文将先说明影视文本与博弈论分析的关系，再分别分析红心 7 与红心 J 的博弈结构，随后比较二者在收益冲突、信息不对称与信任机制上的递进关系，最后集中讨论反事实路径对人物选择稳定性的启示。

2 文献与理论基础

博弈论本身具有较强的抽象性，初学者往往需要在玩家、策略、收益和均衡之间建立较高程度的形式化理解。如果只依赖公式推导和概念说明，学生容易将博弈论理解为脱离现实情境的数学工具，而难以意识到战略互动广泛存在于社会关系、组织决策和日常选择之中。Dixit^[4] 较早提出，博弈论教学可以通过更具趣味性和现实感的材料展开，以降低概念理解门槛，并帮助学习者从具体情境中把握策略互动的逻辑。

已有影视博弈研究的主要价值，不在于把影视作品作为理论的简单例证，而在于提供了一种将叙事情境转化为分析单元的方法。Geerling 等^[1] 对《鱿鱼游戏》的处理并非按照剧情顺序展开，而是选取若干具有明确策略冲突的片段，将其组织为可讨论的教学场景。这种写法提示本文，在分析《弥留之国的爱丽丝》时，应避免将红心游戏处理成单纯的剧情复述，而应优先识别规则变化、信息差异和策略冲突所形成的决策节点。

围绕《弥留之国的爱丽丝》的既有研究已经为本文提供了研究对象层面的铺垫。Anggrela 等^[2] 关注有栖良平在死亡游戏中的人格发展，指出死亡游戏推动人物从消极、自我怀疑的状态走向更强的反思能力、生存意志和行动能力。Khan 和 Pembecioğlu^[3] 则从游戏化学习、协作生活、分析思维和问题解决能力等角度理解该作品，强调屏幕叙事与数字文化中的决策能力之间的关系。上述研究说明，《弥留之国的爱丽丝》已经可以作为人物成长、决策能力和游戏化思维的学术分析对象，但它们更多关注角色发展或观众能力启发，对具体游戏规则如何塑造收益结构、信息限制和策略互动的讨论仍不充分。

因此，本文并不将《弥留之国的爱丽丝》作为单纯的故事文本来讨论，而是将其中的红心游戏视为一种经过叙事包装的战略互动场景。红心 7 与红心 J 都以死亡惩罚为背景，但真正值得分析的并不只是死亡本身，而是规则如何改变玩家之间的收益关系，信息如何影响玩家的判断，信任如何被建立、利用和瓦解。本文借鉴影视博弈分析的处理方式，先从游戏规则出发，再抽取关键决策节点，最后将人物行为转化为策略选择，并讨论不同策略组合下的结果与均衡。

非合作博弈关注的是没有外部强制契约约束时，理性玩家如何在相互影响的条件下进行策略选择。Osborne 和 Rubinstein^[5] 将博弈论视为研究互动决策的理论工具，其中玩家的收益不仅取决于自身行动，也取决于其他玩家的行动。Gibbons^[6] 也强调，博弈论的核心问题在于把现实中的互动情境转化为可分析的玩家集合、策略集合和收益函数。对于本文而言，这意味着红心游戏

中的人物不应只被理解为剧情角色，而应进一步被抽象为具有目标、约束和策略空间的玩家。

红心 7“躲猫猫”最突出的结构特征是唯一生存名额。游戏规则规定倒计时结束时只有狼能够存活，羊则会死亡。由于一名玩家获得生存资格往往意味着其他玩家失去生存资格，该游戏呈现出接近零和博弈的收益结构。在零和博弈中，一方收益的增加通常对应另一方收益的减少。虽然红心 7 中的人物关系包含友情、愧疚和牺牲等非物质因素，但在基本规则层面，生存名额的唯一性使玩家之间首先被推入竞争关系。

这一结构也解释了为什么红心 7 中的合作承诺很难稳定。若玩家仅以生存作为最高收益，则争夺狼身份具有明显诱因。只要规则允许身份在最后阶段通过对视发生转移，任何处于死亡风险中的玩家就仍然存在偏离承诺的动机。由此可见，红心 7 的悲剧并不只是人物缺乏信任造成的，而是规则本身削弱了承诺的可信性。所谓友情的瓦解，实质上是既有情感关系被嵌入零和收益结构之后产生的策略结果。

纳什均衡概念可以进一步解释这种稳定性问题。纳什均衡强调在给定他人策略的情况下，每个玩家都没有单方面改变策略以提高自身收益的动机。对于红心 7 而言，单纯的合作或口头承诺难以构成稳定均衡，因为任何处于死亡风险中的玩家都可能通过争夺狼身份改善自身结果。只有当玩家的收益函数发生变化，将朋友生存、道德责任或自我牺牲意义纳入自身收益时，放弃生存机会才可能获得解释。因此，红心 7 中的牺牲行为不能简单理解为标准理性选择，而应理解为人物偏好结构变化后的特殊选择。

与红心 7 相比，红心 J“单人牢房”的核心问题并不是唯一生存名额，而是信息不对称。Akerlof^[7]在“柠檬市场”研究中指出，当交易双方掌握的信息不一致时，市场结果可能受到严重影响。虽然该理论最初用于解释二手车市场中的质量不确定性，但其核心逻辑同样适用于红心 J 的情境。玩家无法观察自己的花色，只能依赖他人告知，因此他人掌握了关于自身生死的重要信息。信息不对称使玩家必须在信任与怀疑之间不断权衡。

Harsanyi^[8]关于不完全信息博弈的研究为红心 J 提供了进一步解释。在不完全信息博弈中，玩家无法完全知道其他玩家的类型、偏好或信息状态，只能基于有限信息形成主观判断。红心 J 中的普通玩家并不知道谁是隐藏的红心 J，也无法确认他人提供的信息是否真实。因此，每一次报花色、结盟、试探和背叛都不仅是单次行动，也是对他人类型的判断过程。玩家需要根据他人的历史行为、语言表达、联盟关系和异常举动不断更新信念。

信号传递理论也可以用于解释红心 J 中的互动结构。Spence^[9]提出，信息较多的一方可以通过信号影响信息较少一方的判断。在红心 J 中，告知他人花色本身就是一种信号。真实信号可以帮助他人存活，虚假信号则可能导致他人死亡。由于红心 J 具有隐藏身份和误导他人的动机，玩家不能仅凭一次信息判断对方是否可信，而需要观察信号在重复互动中的稳定性。由此，信任并不是天然存在的道德关系，而是在多轮互动中通过行为记录、声誉积累和交叉验证逐渐形成的策略资源。

红心 J 也体现出重复博弈中的声誉机制。玩家在每一轮中的行为会影响他人在下一轮对其可信度的判断。若某一玩家持续提供正确信息，其声誉会提高，更容易获得他人合作。若某一玩家出现说谎、诱导或选择性告知，其声誉会下降，并可能被其他玩家孤立或反制。然而，红心 J 的特殊性在于，隐藏敌人可能故意在前期提供真实信息来建立声誉，再在关键时刻释放虚假信号。这使得完全信任并不安全，完全不信任也不可行。相对稳定的策略不是无条件相信某个人，而是建立有限信任，并通过多人交叉验证降低被单一信号误导的风险。

基于上述理论，本文将红心 7 与红心 J 分别放在收益结构和信息结构两个层面进行分析。红心 7 侧重考察唯一生存名额如何影响玩家之间的承诺稳定性，红心 J 侧重考察信息不对称如何影

响玩家之间的信任判断。

在具体分析路径上，本文采用规则识别、节点拆解、模型转化、均衡解释和反事实讨论的方式展开。后文将先进入两个红心游戏的具体分析，再在讨论部分集中处理替代路径问题。

3 红心 7 “躲猫猫”的非合作博弈分析

红心 7“躲猫猫”发生在植物园式的游戏场地内，主要参与者为有栖良平、苺部大吉、势川张太和紫吹小织。游戏虽然名为“躲猫猫”，但其核心规则以“狼”与“羊”的身份转换展开：初始状态下有一名玩家为“狼”，其余玩家为“羊”；当狼与羊发生对视后，狼的身份会转移给被对视的羊；倒计时结束时，只有最终处于狼身份的玩家能够存活，其余羊身份玩家则会死亡。由此可见，该游戏并不只是单纯的追逐或躲避游戏，而是通过“最终只能有一人活着离开”的规则，将所有玩家推入高度冲突的生存竞争之中。

按照“剧情—模型—解释”的处理思路，本文先将红心 7 的剧情压缩为几个可分析节点。游戏开始后，众人发现难度为红心 7，并意识到朋友之间最终只能有一人存活；在求生压力下，昔日好友一度相互搏斗；有栖在绝望中选择寻找同伴，并放弃自己的存活机会；最后，紫吹小织、势川张太和苺部大吉在回忆友情之后躲藏起来，只有有栖良平成为唯一生还者。上述情节说明，红心 7 的关键不在于人物之间是否存在友情，而在于规则如何把友情置入一个接近零和的收益结构之中。若某一玩家最终成为狼，该玩家获得生存收益，而其他玩家则承担死亡损失。换言之，玩家之间原本可以依靠友情维系的合作关系，被游戏规则重新定义为围绕唯一生存名额展开的策略竞争。

在正式分析中，本文将红心 7 中的主要人物抽象为理性玩家，将其行为选择转化为策略集合。需要说明的是，这里的“理性”并不意味着人物一定冷酷或自私，而是指玩家会在给定规则、时间压力和信息条件下，根据自身偏好选择相对有利的行动。博弈论中的玩家、策略和收益并不是对人物性格的道德评价，而是对其所处决策结构的形式化表达^[5, 6]。

表 1: 红心 7“躲猫猫”的玩家、策略与收益结构

分析维度	内容说明
玩家	有栖良平、苺部大吉、势川张太、紫吹小织等参与者均可视为游戏中的玩家
策略	争夺狼身份、逃避对视、寻找他人、隐藏自身、口头承诺、主动牺牲
核心收益	最终成为狼意味着生存，最终成为羊意味着死亡
信息条件	玩家知道基本规则，也知道狼身份可以通过对视发生转移
关系基础	玩家之间存在熟人关系和情感纽带，但规则削弱了承诺的稳定性
博弈类型	接近零和博弈的非合作生存博弈
主要矛盾	生存竞争与友情承诺之间的冲突

表 1 表明，红心 7 的规则结构具有明显的非合作特征。虽然玩家之间可以进行交流，也可以尝试建立承诺，但游戏并没有提供任何外部执行机制来保证承诺不会被违背。尤其是在倒计时接

近结束时，任何仍处于羊身份的玩家都面临死亡压力，因此其偏离原有承诺并重新争夺狼身份的动机会显著增强。这也是红心 7 区别于一般合作游戏的重要之处。合作并非完全不可能，但合作很难稳定。

为了避免将红心 7 分析写成单纯剧情复述，本文将该游戏拆解为若干关键决策节点。每个节点都对应一个具体的策略问题。玩家并不是在抽象地面对“生存还是死亡”，而是在不同时间点上不断面对更具体的选择，例如是否争夺狼身份，是否相信朋友承诺，是否继续寻找其他玩家，是否主动牺牲，以及是否重新理解自己与他人的收益关系。

表 2: 红心 7“躲猫猫”的关键决策节点

决策节点	具体问题	可选策略	对应博弈概念
规则公布后	玩家如何理解唯一生存名额	争夺狼身份或暂时观望	零和博弈，非合作博弈
身份转移阶段	玩家是否主动制造对视	主动追逐，逃避对视，隐藏自身	策略互动，收益冲突
口头承诺阶段	玩家是否相信朋友承诺	接受承诺，怀疑承诺，重新竞争	承诺可信性，背叛风险
倒计时后期	玩家是否继续争夺狼身份	最后争夺，放弃争夺，主动牺牲	纳什均衡，偏好变化
结局前选择	个体生存是否仍是最高收益	保全自身，成全他人	利他偏好，非标准收益函数

分析表 2 可得到，红心 7 的剧情推进可以被转化为一组连续的策略选择。前期玩家可能仍然保留合作幻想，但随着倒计时推进，游戏结构中的零和特征不断强化。此时，玩家对他人承诺的信任程度会下降，个体生存收益会被放大，合作关系也更容易被重新解释为策略风险。

这一点也说明，红心 7 并不是简单的“朋友之间互相伤害”的故事。更准确地说，它展示了熟人关系在高压生存规则下如何被重新编码。当规则将唯一生存名额置于所有玩家面前时，友情不再只是情感关系，也变成影响收益判断和策略选择的变量。玩家既要考虑自己是否能活下来，也要考虑他人是否会在最后阶段改变策略。

为了进一步说明红心 7 中的非合作压力，可以将其简化为两名玩家之间的策略互动。这里以有栖良平和苧部大吉为例进行模型化处理。需要强调的是，得益矩阵中的数值不是对人物心理收益的实证测量，而是参照影视博弈案例教学中常见的做法^[1]，根据剧情规则对相对收益进行顺序化编码。矩阵只要求表达不同结果之间的大小关系，而不要求数值具有精确计量意义。

该矩阵的赋值依据如下。第一，最终成为狼并存活是规则给出的最高收益，因此记为 10。第二，作为羊死亡是游戏中的最低结果，因此记为 -10。第三，双方都争夺狼身份时，二人都付出关系破裂、搏斗和心理崩溃的代价，但至少仍保留改变身份的机会，因此用 -5 表示一种高冲突、低稳定但并非立即接受死亡的状态。第四，双方都放弃争夺时，友情和道德意义得到保留，但无人能够稳定取得生存资格，结局仍趋向共同死亡，因此记为 -8。这一排序体现的是“生存收益最高、死亡损失最低、冲突状态优于直接放弃但伴随重大关系成本”的剧情判断。

表 3: 红心 7 中有栖良平与莉部大吉的简化得益矩阵

	莉部争夺狼身份	莉部放弃争夺
有栖争夺狼身份	$(-5, -5)$	$(10, -10)$
有栖放弃争夺	$(-10, 10)$	$(-8, -8)$

从表 3 可以看出, 如果玩家只以个体生存作为最高收益, 那么争夺狼身份具有较强的策略吸引力。当对方放弃争夺时, 自己争夺可以获得最高收益。当对方争夺时, 自己若放弃则几乎确定死亡, 若争夺至少仍有改变结果的可能。因此, 在纯粹生存理性下, 玩家很难稳定地选择放弃争夺。剧情中朋友从搏斗转向躲藏和牺牲, 恰恰说明他们最后并非沿着狭义生存收益最大化行动, 而是让友情、愧疚和继承意志进入收益函数。

这也解释了为什么口头承诺面临可信性问题。某一玩家可以承诺自己不会争夺狼身份, 也可以承诺让他人活下去, 但其他玩家无法确认该承诺在最后时刻仍会被遵守。在倒计时压力下, 任何玩家都可能重新评估生存收益和承诺成本。由此可见, 红心 7 中的合作困境并不只是人物缺乏道德, 而是承诺结构本身缺少稳定基础。

纳什均衡的视角可以进一步说明这一点。若在给定他人策略的情况下, 某一玩家可以通过单方面改变策略提高自身收益, 那么当前策略组合就不是稳定均衡。对于红心 7 而言, 如果一名玩家相信其他人会放弃争夺, 那么自己争夺狼身份能够获得最高生存收益。如果一名玩家相信其他人会争夺, 那么自己继续争夺也可能优于直接放弃。因此, 在以生存为最高收益的基础模型中, 非合作策略具有很强的稳定性。合作只有在玩家的收益函数发生变化后才可能出现。

红心 7 的特殊之处在于, 剧情并没有停留在纯粹的生存竞争。随着游戏推进, 人物之间的情感关系、愧疚感和自我认同开始改变个体对收益的理解。对于标准博弈模型而言, 生存通常被设定为最高收益, 死亡则是最低收益。然而, 红心 7 中的牺牲行为表明, 人物的收益函数可能并不只包含生理生存, 还可能包含朋友能否存活、自身是否背叛友情、是否保留道德意义等因素。

因此, 红心 7 的结局不能简单解释为非理性行为。若玩家将“让朋友活下去”视为一种高于自身生存的价值, 那么主动牺牲就不再是收益最小化, 而是偏好结构改变后的策略选择。这种选择不符合狭义的自利理性, 却可以在扩展收益函数中获得解释。换言之, 人物并不是不知道争夺狼身份可以提高生存概率, 而是在最后阶段重新定义了什么才是对自己而言更重要的结果。

已有角色研究也能从叙事层面支撑这一点。Anggrela 等^[2]认为, 红心 7 中朋友的死亡与牺牲构成有栖人格变化的重要节点, 使其重新理解自身价值, 并获得继续生存和继承朋友意志的动机。本文在此基础上进一步指出, 这种人物变化也可以转化为博弈论语言来理解: 当朋友存活、道德责任和继承意志被纳入个体收益函数时, 牺牲或接受牺牲就不再只是单纯的非理性行为, 而是收益排序变化后的策略结果。

这一点对于本文的分析十分关键。红心 7 并不是要说明人在极端情境下必然自私, 也不是要说明友情一定能够战胜死亡恐惧。极端情境的分析价值在于, 它把理性计算、求生本能和情感偏好压缩到同一决策结构之中, 使人物选择背后的博弈关系更加清晰。它更复杂的地方在于, 规则首先将玩家推入非合作结构, 随后又让人物在这一结构中重新面对自身偏好。正因为争夺狼身份在生存理性下具有强吸引力, 主动牺牲才具有强烈的博弈意义。牺牲并不是规则自然导出的均衡结果, 而是人物通过改变收益权重对规则压力作出的回应。

由此可见, 红心 7 呈现出的不是单一人物的性格悲剧, 而是零和规则、时间压力和承诺不可

信共同作用下的结构性困境。剧情结尾的躲藏与牺牲并非简单否定博弈理性，而是说明人物在规则压力下重新调整了收益排序。

4 红心 J “单人牢房”的信息不对称与信任博弈分析

如果说红心 7“躲猫猫”的核心矛盾在于唯一生存名额所造成的零和竞争，那么红心 J“单人牢房”的核心矛盾则在于信息不对称所造成的信任困境。该游戏发生在东京一座监狱中，主要参与者包括苜屋骏太郎、盘田素那斗、松下苑治、矢场旺希、琴子以及十多名其他玩家。所有玩家佩戴颈环，颈环在后颈处显示扑克牌花色；玩家无法看到自己的花色，只能依靠他人告知。每过一小时，玩家必须回到单人牢房并回答自己的花色，答错者死亡，答对者进入下一回合，且下一回合花色可能改变。游戏没有总时限，监狱内也有足够粮食；玩家通关的条件不是熬到时间结束，而是使混入玩家之中的红心 J 答错花色并死亡。

由此可见，红心 J 并不是一个单纯的记忆或猜测游戏。它的关键在于，玩家必须依赖他人才能获得自身生存所必需的信息，但又无法完全确认他人提供的信息是否真实。更复杂的是，红心 J 本人也无法看到自己的花色，因此他一方面需要他人信息维持生存，另一方面又具有误导普通玩家、破坏信任并隐藏身份的动机。信息在这里不再只是辅助条件，而是决定生死的核心资源。玩家之间的互动也不再只是身体竞争或直接对抗，而是围绕“谁值得相信”“哪些信息可以验证”“谁可能是隐藏的红心 J”展开的动态判断过程。

按照剧情推进，前期玩家们结成信任团队并互相如实告知花色，因而顺利通过最初几轮；中期开始出现说谎，部分玩家因相信虚假信息而死亡，信任网络随之崩塌。苜屋选择一名忠厚良善的玩家作为搭档并通过多个回合，但该搭档最终承受不了猜疑氛围而放弃回答并死亡。游戏后期只剩苜屋、盘田、松下、矢场和琴子五人：苜屋认出盘田是连环杀人案死囚，盘田与表面脆弱的松下结成搭档，矢场与琴子因亲密关系形成稳定搭档，苜屋则处于孤立状态。关键回合中，盘田与矢场建立互信并确认彼此不是红心 J；琴子故意向矢场提供错误花色，但自己也没有按照矢场提供的正确花色回答，最终死亡。随后苜屋、盘田和矢场共同指出松下就是红心 J，因为松下早期主动靠近盘田的行为与其脆弱人设不符，且松下与琴子一直通过暗号确认彼此花色。由此，红心 J 可以被理解为一个具有不完全信息特征的动态信任博弈。Akerlof^[7] 关于信息不对称的研究说明，当互动双方掌握的信息不一致时，行为结果会受到信息差异的深刻影响。Harsanyi^[8] 关于不完全信息博弈的研究进一步指出，玩家往往无法直接知道其他玩家的类型和真实意图，只能根据有限信息形成判断。红心 J 正是如此。

表 4: 红心 J“单人牢房”的玩家、策略与信息结构

分析维度	内容说明
玩家	菅屋骏太郎、盘田素那斗、松下苑治、矢场旺希、琴子及其他玩家，其中松下苑治为隐藏身份的红心 J
核心规则	玩家无法看到自身花色，每小时返回囚室回答花色，答错死亡，答对进入下一回合
普通玩家策略	如实告知、寻求他人告知、固定结盟、交叉验证、怀疑与排除
红心 J 策略	隐藏身份、选择性提供真实信息、制造误导、破坏联盟、诱导错误回答
核心收益	普通玩家需要回答正确并促使红心 J 死亡，红心 J 需要隐藏身份、误导他人并延长生存
信息条件	玩家掌握他人花色信息，但无法直接观察自身花色，也无法确定他人类型；红心 J 同样不知道自己的花色
时限与物资	游戏无总时限，监狱内有足够粮食，时间压力主要来自每小时一次的回答节点
过关条件	只有红心 J 答错花色并死亡时，普通玩家才能赢得游戏
博弈类型	不完全信息博弈、信号传递博弈、重复博弈
主要矛盾	信任建立与信息操控之间的冲突

表 4 表明，红心 J 的复杂性来自双重信息不对称。第一重信息不对称存在于玩家自身花色和他人观察之间。玩家无法知道自己的花色，却必须依赖他人告知。第二重信息不对称存在于玩家身份和真实意图之间。普通玩家不知道谁是红心 J，也不知道某个玩家提供信息时究竟是出于合作、试探还是误导。正是这两重信息不对称，使红心 J 中的信任关系具有高度不稳定性。

在这种规则结构下，玩家的理性策略不可能是简单地相信所有人，也不可能是完全拒绝他人信息。完全信任会使玩家容易被虚假信号操控，完全不信任则会使玩家无法获得回答自身花色所需的信息。因此，红心 J 中的核心策略问题不是“信任或不信任”这一简单二分，而是在不完全信息环境中如何建立有限信任、如何进行交叉验证，以及如何根据他人的行为持续更新判断。

与红心 7 类似，红心 J 也可以被拆解为若干关键决策节点。不同之处在于，红心 7 的决策节点主要围绕生存名额展开，而红心 J 的决策节点主要围绕信息可信度展开。每一名玩家都必须在多个层面上作出判断，包括向谁询问花色，是否相信对方提供的信息，是否与某人固定结盟，是否公开共享信息，以及是否怀疑某人具有红心 J 身份。

表 5: 红心 J“单人牢房”的关键决策节点

决策节点	具体问题	可选策略	对应博弈概念
第一轮信息交换	玩家应当相信谁提供的花色	相信单一对象，询问多人，暂时观察	信息不对称，信号识别
联盟形成阶段	玩家是否建立固定搭档关系	两两绑定，多人联盟，保持孤立	联盟博弈，重复博弈
信任积累阶段	玩家如何判断对方是否可信	根据历史准确率判断，根据他人评价判断，交叉验证	声誉机制，贝叶斯更新
怀疑出现阶段	玩家如何处理可疑信息	继续信任，降低信任，主动试探，公开质疑	信念更新，策略性怀疑
红心 J 识别阶段	玩家如何锁定隐藏敌人	观察异常行为，比较信息矛盾，诱导暴露	不完全信息博弈，信号反制

表 5 说明，红心 J 的博弈过程具有明显的动态性。玩家并不是在某一时刻一次性决定是否信任他人，而是在多轮互动中不断修正判断。某个玩家在前几轮提供正确信息，并不意味着其在后续回合一定继续可信。相反，隐藏身份的红心 J 可能通过前期合作建立声誉，再在关键节点释放错误信息，从而实现更有效的误导。由此可见，红心 J 中的信任并不是静态状态，而是一种不断被生产、检验和重估的策略资源。

红心 J 中的“报花色”行为可以被视为一种典型的信号传递。Spence^[9] 提出，信息较多的一方可以通过信号影响信息较少一方的判断。在红心 J 中，观察到他人花色的玩家拥有信息优势，而无法观察自身花色的玩家则处于信息劣势。前者通过语言告知后者花色，这一告知行为就是信号。若信号真实，接收者可以存活。若信号虚假，接收者可能死亡。

然而，信号能否被相信，并不只取决于信号内容本身，还取决于信号发送者的身份、动机和历史行为。普通玩家提供真实花色，可能是为了互相合作并延长生存时间。红心 J 提供真实花色，则可能是为了隐藏自己并积累可信声誉。红心 J 提供虚假花色，则可能是为了淘汰其他玩家并制造群体恐慌。因此，相同的“告知花色”行为，在不同玩家类型下具有不同含义。

红心J“单人牢房”：信号传递与信任建立机制图




图 2：红心 J“单人牢房”的信息传递与信任验证网络

如图 2 所示，红心 J 中的信息流并不是单向和透明的，而是由多个玩家之间的观察、告知、验证和怀疑共同构成。每名玩家既可能是信息发送者，也可能是信息接收者。玩家之间的关系也不是简单的朋友或敌人，而是随着每轮信息交换不断变化的信任网络。

在这一网络中，信任的建立通常依赖重复互动。如果某一玩家连续多轮提供正确信息，其可信度会提升，其他玩家也更愿意与其结盟。这体现了重复博弈中的声誉机制。声誉并不是玩家天然拥有的属性，而是在多轮行动中被逐步积累出来的结果。然而，红心 J 的存在使声誉机制变得复杂。隐藏敌人可以利用真实信号伪装成合作者，也可以利用局部合作换取长期信任。由此可见，声誉虽然能够降低不确定性，但并不能完全消除背叛风险。

在红心 J 中，玩家面临三种基本信任策略。第一种是完全信任，即玩家依赖某个对象提供的信息，并直接根据该信息回答自己的花色。第二种是完全不信任，即玩家拒绝依赖他人信息，试图独立行动。第三种是有限信任与交叉验证，即玩家可以暂时接受某些信息，但会通过多名玩家、多个回合和行为一致性进行验证。

从策略效果看，完全信任的短期成本最低，因为玩家只需要依赖固定对象即可获得答案。如果对方确实可信，这种策略可以减少沟通成本并提高行动效率。但是，一旦对方是红心 J，或者在关键时刻选择背叛，完全信任就会带来极高风险。完全不信任看似能够避免被欺骗，但由于玩家无法观察自身花色，这种策略实际上会使玩家失去生存所必需的信息来源。因此，完全不信任也不是稳定策略。

相较而言，有限信任与交叉验证更符合红心 J 的规则环境。玩家可以选择暂时相信某一信息来源，但不将其视为唯一依据。通过询问多名玩家、比较不同信息是否一致、观察信息发送者的历史行为，玩家可以降低被单一虚假信号误导的概率。这一策略并不能彻底消除风险，但能在信息依赖和背叛防范之间取得相对平衡。

表 6: 红心 J 中三种信任策略的比较

策略类型	策略特征	主要优势	主要风险
完全信任	依赖单一对象提供花色信息	沟通成本低, 行动效率高	容易被红心 J 或背叛者利用
完全不信任	拒绝依赖他人信息, 尽量独立判断	减少被单一对象操控的风险	无法获取自身花色, 生存概率下降
有限信任与交叉验证	暂时相信部分信息, 同时通过多人和多轮验证	兼顾信息获取与风险控制	沟通成本较高, 仍可能被多人合谋误导

表 6 表明, 红心 J 的理性策略并不是绝对合作, 也不是绝对孤立, 而是在有限信任基础上的动态验证。这与红心 7 形成鲜明对比。红心 7 中, 合作承诺之所以困难, 是因为唯一生存名额使玩家之间的收益高度冲突。红心 J 中, 合作之所以困难, 则是因为信息真实性无法被立即确认。前者的问题是收益结构接近零和, 后者的问题是信息结构高度不对称。

为了进一步说明红心 J 中的信任困境, 可以将其简化为信息接收者与信息发送者之间的互动。这里的玩家 A 代表需要获知自身花色的信息接收者, 玩家 B 代表掌握 A 花色信息的发送者; B 既可能是普通玩家, 也可能是隐藏红心 J 或其暗中同盟。因此, 矩阵并不假定所有普通玩家都有说谎收益, 而是刻画“信息发送者具有欺骗动机”时, 接收者如何在直接信任与交叉验证之间选择。若 A 直接信任且 B 说真话, 双方都能以较低成本通过本回合。若 A 直接信任而 B 说假话, A 可能因答错花色死亡, B 则可能获得淘汰对手、制造混乱或保护隐藏身份的收益。若 A 交叉验证, 则会付出沟通和时间成本, 但能够降低被单一虚假信号杀死的风险。

表 7: 红心 J 中信息告知与信任选择的简化得益矩阵

	信息发送者 B 说真话	信息发送者 B 说假话
玩家 A 直接信任	(5, 5)	(-10, 8)
玩家 A 交叉验证	(3, 4)	(2, -3)

表 7 中的数值同样是相对收益, 其依据来自剧情中“如实告知—顺利过关”“虚假告知—答错死亡”“交叉询问—降低风险但增加成本”的规则关系。(5, 5) 表示前期玩家如实互报花色时的高效率合作: A 获得正确信息, B 也积累合作声誉。(-10, 8) 表示 A 直接相信谎言后的死亡损失, 以及 B 在欺骗成功时获得的淘汰竞争者或扰乱信任网络收益; 该收益低于红心 7 中的生存最高值, 是因为说谎会留下声誉风险和身份暴露风险。(3, 4) 表示 A 进行交叉验证且 B 说真话时, 双方仍可生存, 但验证成本和被怀疑的成本使收益低于无成本信任。(2, -3) 表示 A 通过验证识别或抵消谎言后避免死亡, B 则因说谎暴露而承担声誉下降、联盟破裂或身份被锁定的损失。琴子向矢场提供错误花色、芭屋通过询问和观察其他四人的反应判断花色, 并最终推断松下身份的情节, 正对应这一验证机制的作用。

从均衡角度看, 红心 J 难以形成“所有人完全信任”的稳定状态。只要群体中存在隐藏的红心

J，虚假信号就始终具有策略价值。对于红心 J 而言，在关键时刻误导他人可以直接减少竞争者并制造混乱。因此，完全信任容易被破坏。另一方面，所有人完全不信任也不是稳定状态，因为玩家无法独立观察自己的花色，若拒绝一切信息交换，就无法完成每轮回答。因此，红心 J 更可能形成一种介于信任和怀疑之间的动态均衡。玩家需要进行信息交换，但同时保留验证机制和怀疑空间。

这种均衡可以概括为“有限信任均衡”。在该状态下，玩家不会无条件相信任何单一对象，也不会完全拒绝合作。玩家会根据历史行为、他人反馈和信息一致性判断某一信号的可信度。若某人多轮提供正确信息，其可信度上升。若某人信息前后矛盾，或其提供的信息与其他人的观察不一致，其可信度下降。由此，信任在红心 J 中成为一种可积累、可消耗、也可被操控的资源。

通过上述分析可以看出，红心 J 中的策略选择并不存在绝对安全的方案。玩家必须依赖他人信息才能生存，但又不能把生死完全交给单一信号。因此，红心 J 呈现的并不是简单的“相信别人会死”或“不相信别人才能活”，而是一个更复杂的信任权衡过程。玩家必须在信息依赖、验证成本和背叛风险之间不断寻找相对稳定的策略。

5 两种红心游戏的比较与理论递进

通过前文分析可以看出，红心 7 与红心 J 虽然都属于红心类型游戏，但二者所呈现的博弈结构并不相同。红心 7 的核心资源是唯一生存名额，玩家的主要目标是争夺最终的狼身份。红心 J 的核心资源则是真实信息，玩家的主要目标是获得关于自身花色的可靠判断，并识别隐藏在群体中的红心 J。前者的冲突来自规则直接制造的生存排他性，后者的冲突来自信息不对称造成的信任不确定性。

这种差异使两个游戏在理论上形成了递进关系。红心 7 更接近零和生存博弈，它展示的是当生存资格只能由一人获得时，熟人之间的友情承诺为什么难以维持。红心 J 则更接近不完全信息条件下的动态信任博弈，它展示的是当玩家必须依赖他人提供信息时，信任如何被建立、检验、操控和破坏。二者共同说明，红心游戏的残酷性并不只是来自死亡惩罚，而是来自规则与信息对玩家关系的重构。

表 8: 红心 7 与红心 J 的博弈结构比较

比较维度	红心 7“躲猫猫”	红心 J“单人牢房”
核心资源	唯一生存名额	真实花色信息
玩家关系	熟人关系，原本存在友情和情感纽带	陌生人关系，依靠临时联盟建立信任
基本规则	最终只有狼能够存活，羊会死亡	玩家无法看到自身花色，必须依赖他人告知
主要矛盾	生存竞争与友情承诺之间的冲突	信任建立与信息操控之间的冲突
信息结构	规则相对明确，结果高度零和	信息不对称，身份与意图难以判断
主要策略	争夺狼身份，逃避对视，承诺让渡，主动牺牲	如实告知，虚假告知，固定结盟，交叉验证
对应理论	零和博弈，非合作博弈，承诺可信性，纳什均衡	不完全信息博弈，信号传递，重复博弈，贝叶斯更新
均衡困境	合作承诺难以稳定，失败者存在偏离动机	完全信任容易被利用，完全不信任无法生存
理论意义	说明规则如何瓦解熟人信任	说明信息如何生产并破坏陌生人信任

表 8 表明，两个游戏虽然都围绕信任展开，但信任失效的原因并不相同。红心 7 中，信任失效主要源于收益结构。只要最终只能有一人存活，合作承诺就会受到死亡风险的持续冲击。红心 J 中，信任失效主要源于信息结构。即使玩家具有合作意愿，也无法确认他人是否真实、稳定、无害地提供信息。因此，红心 7 中的信任困境更接近“利益冲突下的承诺不可信”，红心 J 中的信任困境更接近“信息不对称下的信号不可信”。

博弈论分析强调，玩家的行动不能脱离规则与收益结构来理解。Osborne 和 Rubinstein^[5] 关于博弈结构的基本讨论说明，玩家、策略和收益共同决定了互动结果。将这一思路应用到红心游戏中可以发现，人物行为并不是单纯由性格决定的，而是在特定规则下被重新塑造的。

在红心 7 中，游戏规则将玩家置于唯一生存名额的竞争中。即便玩家之间原本存在友情，规则仍然使得生存收益与他人死亡结果高度绑定。正因如此，任何只依赖口头约定的合作都缺少稳定的执行基础。玩家不是不知道合作更温和，而是因为合作结果无法被规则保障。只要某一玩家在最后阶段仍然能够通过对视改变狼身份，那么该玩家就始终具有偏离协议的可能。

红心 J 的规则对收益结构的改变方式则不同。它并不直接规定只有一名普通玩家能够存活，而是让每名玩家都必须依赖他人信息才能活下去。这样一来，玩家的收益不仅取决于自身判断能力，也取决于他人是否愿意提供真实信息。信息发送者因而获得策略优势。普通玩家可以通过真实信号建立信任，红心 J 也可以通过真假混合的信号操控他人。由此，信息本身成为一种可以影响收益分配的资源。

因此，红心 7 和红心 J 都说明了一个共同问题。死亡游戏中的人物选择并不是在抽象道德空间中发生的，而是在规则塑造出的收益空间中发生的。规则不是背景，而是决定玩家关系的核心

机制。规则一旦改变，友情、合作、信任和背叛的含义也会随之改变。

红心 7 与红心 J 也可以被理解为信任机制的两种瓦解方式。红心 7 展示的是信任被零和规则瓦解。玩家之间即使愿意相信彼此，也无法消除唯一生存名额带来的根本冲突。信任在这里面临的是收益层面的压力。只要一方生存意味着另一方死亡，信任就难以成为稳定策略。换言之，红心 7 中的问题不是玩家无法交流，而是交流无法改变零和收益结构。

红心 J 展示的则是信任被信息不对称瓦解。玩家之间必须交流，也必须在一定程度上依赖他人。问题在于，交流本身可能被操控。某个玩家说出的花色可能是真实信息，也可能是红心 J 释放的误导信号。信任在这里面临的是信息层面的压力。玩家不是没有合作需求，而是无法确认合作对象的真实身份与真实意图。

这两种瓦解方式对应两种不同的博弈困境。红心 7 中的困境是“我是否愿意牺牲自己的收益来成全他人”。红心 J 中的困境是“我是否能够判断他人的信息是否可信”。前者强调收益冲突，后者强调信念不确定。前者导致承诺不稳定，后者导致信号不稳定。由此，两个游戏在理论上不是简单并列，而是从收益冲突推进到信息冲突，从熟人关系推进到陌生人社会，从个体生存推进到群体信任。

红心 7 和红心 J 都不是简单否定合作可能性的游戏。相反，它们都说明合作可以出现，但合作必须受到规则、信息和执行条件的限制。红心 7 中，合作之所以困难，是因为缺乏能够约束偏离行为的机制。玩家即便达成协议，也无法保证协议在最后阶段被遵守。红心 J 中，合作之所以困难，是因为玩家无法确认合作对象是否真实可信。即便某个玩家连续提供正确信息，也可能只是隐藏敌人积累声誉的策略。

因此，两个游戏都指向一种有限合作的逻辑。红心 7 中的合作只有在玩家收益函数发生变化时才可能稳定，例如牺牲者将朋友生存视为高于自身生存的价值。红心 J 中的合作只有在验证机制存在时才更可靠，例如玩家通过多人交叉确认和多轮观察降低虚假信号风险。前者说明合作需要偏好基础，后者说明合作需要信息基础。

这一点可以回应本文开头提出的问题。关键人物为什么没有选择其他路径，并不是因为他们完全没有选择，而是因为多数路径缺乏稳定条件。角色看似可以选择合作、隐瞒、背叛或牺牲，但这些选择能否成为稳定结果，取决于收益结构是否支持，信息条件是否允许，偏离行为是否能够被约束。

综合前文，本文可以将红心 7 与红心 J 的递进关系概括为三层。第一层是玩家关系的递进。红心 7 发生在熟人关系中，红心 J 发生在陌生人关系中。第二层是核心资源的递进。红心 7 争夺的是唯一生存名额，红心 J 争夺的是可靠信息。第三层是理论问题的递进。红心 7 强调零和规则如何破坏承诺，红心 J 强调信息不对称如何重塑信任。

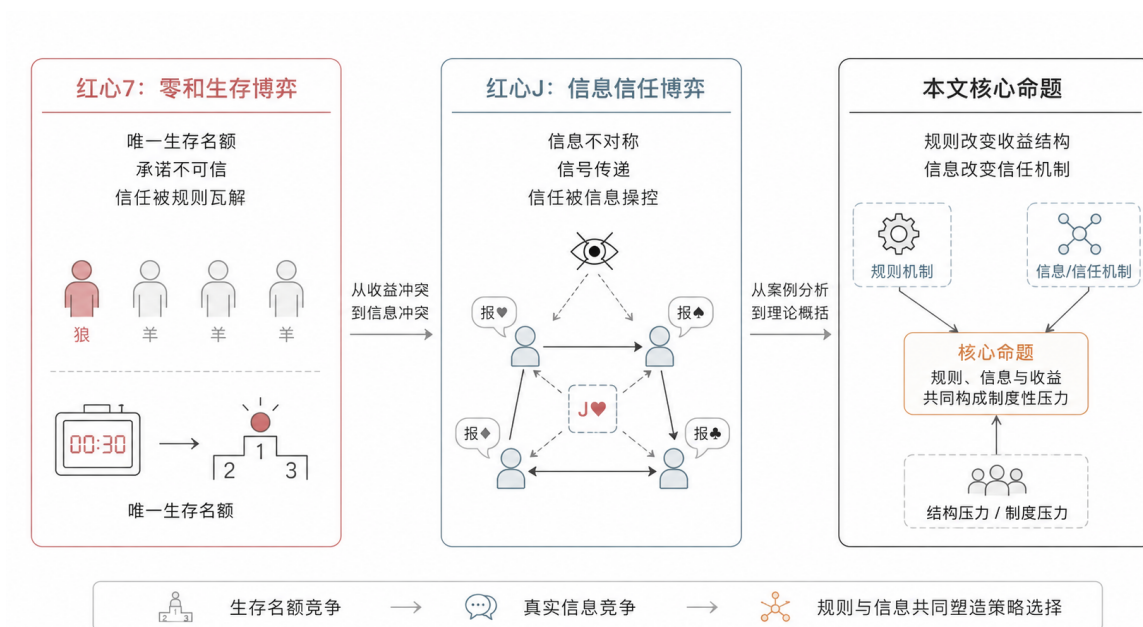


图 3: 红心 7 与红心 J 的理论递进关系

如图 3 所示，红心 7 和红心 J 共同构成了从“零和生存博弈”到“信息信任博弈”的递进链条。红心 7 说明，规则可以通过改变收益结构瓦解熟人之间的信任。红心 J 说明，信息可以通过改变判断条件重塑陌生人之间的信任。两者共同指向本文的核心命题。死亡游戏中的残酷并不只来自惩罚，而来自规则、信息和收益共同构成的制度性压力。

这一递进关系也使本文区别于一般剧情解读。一般剧情解读往往关注人物是否善良、是否背叛、是否牺牲。本文则关注这些行为背后的结构性原因。也就是说，本文并不简单评价人物选择，而是分析这些选择在何种规则下成为合理策略，在何种信息条件下失去稳定性，又在何种偏好变化下发生转向。通过这种方式，《弥留之国的爱丽丝》中的红心游戏可以被理解为非合作博弈与信任机制的叙事化呈现。

6 讨论：反事实路径与策略稳定性

在完成两个案例的规则与模型分析之后，才适合进入 if 线讨论。这里的反事实推演并不是为了改写剧情，而是回应观众最自然的疑问：如果角色换一种做法，结果是否会更好？从博弈论角度看，关键并不在于某条路径看起来是否更善良、更聪明或更公平，而在于它能否在原有规则下保持稳定。换言之，if 分析检验的是替代方案能否同时处理生存压力、信息限制和偏离动机。

红心 7 最容易引发的疑问是：既然有栖良平、苅部大吉和势川张太是好友，他们是否可以一开始就商量出一个更和平的办法？第一种可能是由四人提前约定让某一个人活下去。这种做法在情感上比相互搏斗更可接受，但它的问题在于缺少执行机制。只要倒计时没有结束，狼的身份仍然可以通过对视转移，任何处于羊身份的人都会在死亡压力下重新面对“是否偏离约定”的诱惑。因此，这一路径的脆弱之处不是人物不够真诚，而是承诺本身无法被规则锁定。

第二种可能是四人始终聚在一起，尝试寻找规则漏洞或共同通关方式。这个路径更符合观众

对“朋友应该一起想办法”的期待，也最接近集体理性。但红心 7 的规则明确把最终生存条件绑定在狼身份上，剧情中也没有提供足够清晰的共同通关线索。在时间持续减少的情况下，寻找漏洞会变成一种高风险搜索：如果找不到漏洞，玩家最终仍要回到唯一生存名额的竞争中。也就是说，这一方案不是完全不合理，而是缺少足够信息支撑，难以成为稳定策略。

第三种可能最接近实际剧情，即有人放弃争夺，让有栖活下去。它能够形成明确结果，却不是一般意义上的理性均衡。苣部、势川张太和紫吹小织最后躲藏起来，并不是因为他们找到了可普遍复制的最优策略，而是因为友情、愧疚、责任和“让有栖继续活下去”的意义改变了他们的收益排序。若换成没有深厚情感关系的玩家，这一路径很难自动出现。因此，红心 7 的 if 线真正说明的是，合作或牺牲并非没有可能，但它们要么缺少执行机制，要么缺少信息基础，要么依赖特殊情感偏好。




图 4: 红心 7“躲猫猫”的 if 线决策推演

红心 J 的反事实问题则不同。观众更容易追问：既然大家只要互相说真话就能活下去，为什么不能一直公开互报花色？这一设想在游戏前期确实有效，因为当所有玩家都如实交换信息时，回答花色几乎没有难度。但红心 J 混在玩家之中，且胜利条件要求红心 J 死亡。只要红心 J 有动机隐藏身份并制造错误信息，全员公开就不是一个可以长期依赖的制度。它的最大弱点在于过分依赖“所有人都诚实”这一前提，而游戏正是通过隐藏敌人破坏这个前提。

另一种自然设想是稳定搭档。剧情中苣屋曾依靠忠厚良善的搭档顺利通过多轮，矢场与琴子、盘田与松下也都形成过搭档关系。搭档策略的好处是成本低、沟通快、责任明确，也更容易通过重复互动建立信任。但它的风险同样明显：一旦搭档本身不可信，玩家就会把生死过度集中在一个信息源上。矢场与琴子的关系正说明，稳定关系未必等于真实信息；松下与盘田的搭档关系也说明，弱者姿态本身可能成为伪装。

更稳健的路径是有限信任与多方验证。苣屋在最后阶段没有固定搭档，却通过询问、观察和分析剩余玩家反应判断自己的花色，并进一步锁定松下身份。这一路径并不追求最高效率，而是优先降低单一信息源带来的致命风险。它的代价是沟通成本更高，也需要玩家具备较强观察能力；但在隐藏敌人已经准备发动攻势的后期，它比单纯相信某个搭档更能抵抗欺骗。因此，红心 J 的

if 线并不是要证明“越怀疑越好”，而是说明信任必须配合验证，才能从情感关系转化为可持续的策略机制。




图 5: 红心 J“单人牢房”的 if 线决策推演

综合来看，两个游戏的反事实路径都指向同一个问题：替代方案不能只看表面是否更好，还要看它是否能承受规则压力。红心 7 中的和平约定会被唯一生存名额和身份可转移规则削弱，红心 J 中的公开合作会被隐藏身份和虚假信号破坏。真正有解释力的 if 分析，不是简单说“他们本来可以这样做”，而是进一步追问：这样做之后，谁有动机偏离？偏离能否被阻止？信息是否足够？代价是否可承受？正是在这些问题上，红心 7 与红心 J 显示出博弈论分析的意义。

7 结论

本文以《弥留之国的爱丽丝》中的红心 7“躲猫猫”和红心 J“单人牢房”为研究对象，尝试从博弈论视角分析死亡游戏中的非合作行为与信任机制。与单纯的剧情解读不同，本文并未将人物行为简单归结为善良、自私、背叛或牺牲，而是从游戏规则出发，将人物转换为玩家，将行为转换为策略，将剧情冲突转换为收益结构和信息结构，并通过得益矩阵、关键决策节点和均衡分析解释人物选择背后的结构性原因。

研究发现，红心 7 的核心矛盾在于唯一生存名额所造成的零和竞争。游戏规则规定最终只有狼能够存活，这使得玩家之间原本存在的友情关系被重新嵌入生存竞争之中。在这一结构下，仅依靠口头承诺的合作虽然具有道德吸引力，却难以形成稳定均衡。原因在于这类承诺缺乏外部执行机制，且失败者在死亡压力下始终存在偏离协议的动机。因此，红心 7 所呈现的并不是简单的人性崩塌，而是零和规则对熟人信任的制度性瓦解。

与红心 7 相比，红心 J 的核心矛盾并不在于唯一生存名额，而在于信息不对称。玩家无法看到自己的花色，只能依赖他人提供信息。与此同时，隐藏身份的红心 J 具有操控信息、误导他人

和破坏信任的动机。因此，红心 J 中的信任并不是天然稳定的关系，而是一种需要通过多轮信号、声誉积累和交叉验证不断生产和检验的策略资源。完全信任容易被隐藏敌人利用，完全不信任又会使玩家失去必要信息。相对而言，有限信任与交叉验证更接近该游戏中的稳健策略。

通过比较可以看出，红心 7 与红心 J 之间形成了清晰的理论递进。红心 7 展示的是“生存名额竞争”如何瓦解熟人之间的承诺与信任，红心 J 则进一步展示“真实信息竞争”如何重塑陌生人之间的合作与怀疑。前者强调收益结构对玩家关系的压迫，后者强调信息结构对信任机制的改造。二者共同说明，红心游戏的残酷性并不只来自死亡惩罚，而来自规则、收益与信息共同构成的制度环境。人物看似拥有多种选择，但许多选择在既定规则下缺乏稳定条件，因而难以成为真正可持续发展的策略。

本文的反事实讨论也表明，所谓“人物没有别的选择”并不意味着人物没有行动空间，而是指许多替代方案无法同时满足生存、合作和稳定三个条件。角色之所以没有选择某些看似更好的路径，并非完全出于情绪或偶然，而是因为这些路径在博弈结构中存在偏离动机、信息缺口或验证成本。反事实路径的意义在于检验策略的稳定性，而不是简单改写剧情。

当然，本文也存在一定局限。由于研究对象是影视文本，剧情本身包含情感表达、人物成长和戏剧化安排，不能被完全还原为标准博弈模型。得益矩阵中的数值也只是对相对收益关系的抽象表达，并不代表角色真实心理收益的精确测量。因此，本文的模型化分析更适合被理解为一种解释框架，而不是严格形式化证明。后续研究可以进一步引入更多红心游戏，或比较黑桃、方块、梅花等不同类型的博弈结构，从而更系统地分析《弥留之国的爱丽丝》中规则设计与人物行为之间的关系。

总体而言，《弥留之国的爱丽丝》中的红心游戏为理解非合作博弈与信任机制提供了具有代表性的叙事场景。红心 7 说明，规则可以通过改变收益结构摧毁熟人关系中的合作基础。红心 J 说明，信息可以通过改变判断条件影响陌生人之间的信任形成。二者共同揭示了一个核心命题，即在高压生存情境下，人的选择并不只是道德品质的体现，也是在理性计算、求生本能、规则信息和收益压力共同作用下形成的策略结果。正是在这一意义上，红心 7 与红心 J 不仅是具有戏剧张力的死亡游戏，也可以被视为分析理性选择、信任边界和均衡条件的博弈论案例。

参考文献

- [1] GEERLING W, NAGY K, RHEE E, et al. Using squid game to teach game theory[J]. Journal of Economics Teaching, 2023, 8(1): 47-63.
- [2] ANGGRELA R F, BUDIMAN F F J, FEBRIYANTI S D. Arisu's personality development across the death games in alice in borderland[J]. Mahakarya: Jurnal Mahasiswa Ilmu Budaya, 2021, 2(2): 63-69.
- [3] KHAN M, PEMBECIOĞLU N. Generation Z-game based analytical thinking and problem-solving skills in digital world vs. collaborative life: “Alice in borderland” analysis[Z]. 2023.
- [4] DIXIT A. Restoring fun to game theory[J/OL]. The Journal of Economic Education, 2005, 36(3): 205-219. DOI: 10.3200/JECE.36.3.205-219.
- [5] OSBORNE M J, RUBINSTEIN A. A course in game theory[M]. Cambridge, MA: MIT Press, 1994.

- [6] GIBBONS R. A primer in game theory[M]. Hemel Hempstead: Harvester Wheatsheaf, 1992.
- [7] AKERLOF G A. The market for lemons: quality uncertainty and the market mechanism [J/OL]. The Quarterly Journal of Economics, 1970, 84(3): 488-500. DOI: 10.2307/1879431.
- [8] HARSANYI J C. Games with incomplete information played by bayesian players, I–III[J/OL]. Management Science, 1967, 14(3): 159-182. DOI: 10.1287/mnsc.14.3.159.
- [9] SPENCE M. Job market signaling[J/OL]. The Quarterly Journal of Economics, 1973, 87(3): 355-374. DOI: 10.2307/1882010.